

Data Preparation With Python

Muhammad Saipul Rohman, S.SI, M.Kom



Outline

- Data Cleansing
- Data Manipulation
- Data Wrangling
- Mengenal EDA



Data Cleansing



Data Cleansing

- Missing Value
- Duplicate Data
- Standardize and Normalize Data
- Import and Export Data



APA YANG DIMAKSUD DENGAN DATA CLEANSING DAN KENAPA HARUS DILAKUKAN?

Data cleansing adalah proses mendeteksi, mengoreksi, dan mengidentifikasi data yang tidak lengkap, tidak benar, tidak akurat atau tidak relevan, untuk kemudian dimodifikasi, diganti, atau dihapus sesuai dengan kebutuhan.




Data Cleansing

Faktanya, data cleansing adalah salah satu proses yang harus dikuasai oleh seorang analis. Selain itu, step ini memakan banyak waktu, sekitar 80% dari keseluruhan proses analisa data.



Penyebab Dirty Data



Jadi Apa yang dimaksud dengan Dirty Data ?

Missing Data

Terdapat informasi yang kosong dalam data.

Duplicate Data

Terdapat informasi yang sama terinput lebih dari 1 kali.

Incorrect Data

Kesalahan dalam proses penginputan, data yang bergeser, kolom dan isi tidak sesuai.

Inconsistent Data

Perbedaan pola penulisan untuk informasi yang sama.

Kesalahan format data


Mengacu pada tipe data dan informasi di dalamnya.

Kesalahan ejaan

Penulisan yang tidak sesuai.



Kenapa Cleansing Data Sangat Penting ?



Permasalahan Umum Yang Memerlukan Data Cleansing?

Missing Value

Duplicate Data

Data yang tidak standar dan normal

Import and Export Data



Missing Value

Cara Menghadapi Missing Value :

- Menghilangkan atau menghapus data yang hilang
- Melakukan inputting value dengan data yang menyerupai seperti minimum value, maximum value, mean, atau modus
- Melakukan manual inputting value dengan data yang sebenarnya (cara ini membutuhkan high effort untuk mencari data yang hilang tersebut)
- Menentukan custom value berdasarkan asumsi bisnis yang terjadi



Data Duplicate

Duplikasi data terjadi ketika terdapat nilai atau ID yang berulang pada suatu data. Permasalahan duplikasi dapat diselesaikan dengan menghapus row yang sama, sehingga hanya tersisa unique value yang akan dianalisa.



Data Yang Tidak Standard dan Normal

Dalam suatu data, terkadang terdapat range nilai yang sangat berbeda antara satu dengan lainnya. Hal ini sering kali menggiring opini bahwa terdapat beberapa kolom yang superior dibanding kolom lainnya dengan nilai yang lebih kecil. Oleh karena itu, suatu data perlu dilakukan standardisasi dan normalisasi agar memiliki skala atau satuan yang sama.

	Fare	Fare_stand	Fare_norm
0	7.2500	-0.502163	-0.048707
1	71.2833	0.786404	0.076277
2	7.9250	-0.488580	-0.047390
3	53.1000	0.420494	0.040786
4	8.0500	-0.486064	-0.047146
5	8.4583	-0.477848	-0.046349
6	51.8625	0.395591	0.038370
7	21.0750	-0.223957	-0.021723
8	11.1333	-0.424018	-0.041128
9	30.0708	-0.042931	-0.004164



Data Yang Tidak Standard dan Normal

Perbedaan antara standardisasi dan normalisasi

Standardisasi

$$Z = \frac{x_i - \mu}{\sigma}$$

dimana $\mu = 0$ dan $\sigma = 1$

Normalisasi

$$Z = \frac{x - \min(x)}{\max(x) - \min(x)}$$

Dimana berdistribusi normal ($Z : 0 \leq z \leq 1$)



Import and Export Data

Import data adalah suatu proses dalam memanggil atau menampilkan dalam suatu tools.

Export data adalah suatu proses menyimpan data dengan format yang diharapkan. Export data dibutuhkan seorang analis setelah pihak terkait melakukan data cleaning, serta memanipulasi data tersebut dan kemudian menyimpan data yang sudah bersih untuk keperluan dokumentasi atau diolah di tools lain.



Data Manipulation



Data Manipulation

- Data Manipulation
- Renaming, Replacing
- Removing
- Filtering Dataset



Apa itu Data Manipulation

Data manipulation adalah suatu proses memanipulasi atau mengubah data agar mudah diorganisir dan mudah untuk dibaca/dipahami.



Jadi apa yang di maksud dengan Data Manipulation ?

Checking and Changing Data Type

Merubah tipe data sesuai dengan kebutuhan. Tipe data: string, float, integer, datetime.

Renaming

Merubah penamaan paling banyak diterapkan dalam pengubahan nama kolom.

Replacing

Paling banyak diterapkan untuk mapping data berdasarkan kondisi tertentu atau merubah format penulisan pada item.

Removing

Menghilangkan kolom atau baris yang tidak diperlukan.

Filtering Data

Memfilter data sesuai dengan kondisi yang dibutuhkan, misalnya berdasarkan kolom atau kondisi/syarat tertentu.



Data Wrangling



Data Wrangling

- Merging
- Grouping
- Transformation
- Data Correlation



Apa itu Data Wrangling ?

Data wrangling adalah kesatuan proses pengolahan suatu data mulai dari mengumpulkan data, memilih data, kemudian mengubah data untuk menghasilkan analisis yang dapat menjawab permasalahan.



Penerapan Data Wrangling

Merging

Penggabungan dua atau lebih tabel menjadi satu tabel untuk memudahkan dalam mengolah data.

Grouping

Digunakan untuk agregasi dan mengelompokkan berdasarkan kolom tertentu.

Transformation

Proses merubah format, struktur, atau nilai dari suatu data. Banyak digunakan setting skala data.

Data Correlation

Untuk mengetahui seberapa besar hubungan antara 2 variabel, apakah dua variabel tersebut memiliki hubungan yang saling berkaitan atau tidak.



Mengenal EDA



Mengenal Exploratory Data Analysis (EDA)

- Apa itu EDA ?
- Mengapa EDA diperlukan ?
- Konsep paling penting dalam melakukan EDA




What is Exploratory Data Analysis (EDA)

Suatu proses dalam memahami suatu data dengan cara mengeksplorasi tiap detail dari data yang dimiliki untuk mengidentifikasi karakteristik dataset.



Mengapa EDA diperlukan ?



Mengapa EDA diperlukan ?

Menghindari kehilangan banyak informasi penting sebagai temuan awal

Menghindari keputusan yang tidak tepat dalam penentuan analisis selanjutnya (tidak terjadi hasil yang misleading)

Menghemat waktu pengerjaan proyek Data Science



Lalu, konsep apa yang paling penting dalam melakukan EDA?

Tulis pertanyaan-pertanyaan terkait problem yang akan dipecahkan dari data yang ada.

Telusuri jawaban dengan memvisualisasikan, mengubah/merapikan, dan memodelkan data.

Gunakan analisis statistika deskriptif yang telah dipelajari untuk menjawab pertanyaan atau menghasilkan pertanyaan baru.



Langkah EDA

Initial Data Exploration: Membaca data, melihat sekilas beberapa baris, menghitung beberapa ringkasan statistik.

1. Data apa yang tersedia?
2. Tujuan dari analisis apakah explanation, prediction, atau forecasting?
3. Apakah variabel target diketahui?
4. Variabel target berbentuk label, kategorik, atau kontinu?
5. Seberapa banyak dan seberapa lama data tersebut tersedia?
6. Apakah data ini relevan? Atau jika tidak, apakah bisa dibuat relevan?
7. Bagaimana dengan kualitas data ini?
8. Apakah ada data tambahan (eksternal)?
9. Siapa yang memahami tentang data ini dengan baik di perusahaan?



Langkah EDA


Data preprocessing

Mengidentifikasi dan mengatasi data duplikat dan missing data: Temukan dan hapus baris duplikat, kemudian ganti nilai yang hilang dengan mean atau modusnya.

PENTING

Garbage In - Garbage Out! Hal ini menjadi bagian dari data pre-processing yang diperlukan agar tidak terdapat kesalahan perhitungan dikarenakan missing value, duplikasi data, dan permasalahan lainnya.



Check data type : Jenis data apa yang dimiliki dan apakah sudah sesuai?



Langkah EDA

Visualisasi data dengan berbagai pilihan visual dan kondisi data Melakukan



a) Univariate Analysis



Langkah EDA

Visualisasi data dengan berbagai pilihan visual dan kondisi data Melakukan



b) Bivariate Analysis



Langkah EDA

Visualisasi data dengan berbagai pilihan visual dan kondisi data Melakukan


c) Multivariate Analysis



Langkah EDA


Visualisasi data dengan berbagai pilihan visual dan kondisi data Melakukan

d) Multivariate Analysis



Langkah EDA

Pahami tren, pola, dan hubungan antar variabel (Correlation Analysis)



Langkah EDA

Pahami tren, pola, dan hubungan antar variabel (Correlation Analysis)

