

Supervised Learning Binary Classification & Logistic Regression

Muhammad Saipul Rohman, S.SI, M.Kom



Outline

- Concept and Definition of Supervised Learning - Classification
- Concept and Definition Logistic Regression
- Hands On Logistic Regression Analysis using Python



Concept and Definition of Supervised Learning - Classification



CLASSIFICATION



BINARY CLASSIFICATION



Special case untuk mengklasifikasikan/ mengkategorikan data ke dalam **2 class**

MULTIPLE CLASSIFICATION



Mengklasifikasikan untuk **> 2 class**



CLASSIFICATION




INPUT DATA



CLASS
LABEL/OUTPUT/TARGET



CLASSIFICATION WORKFLOW



BEBERAPA METODE MACHINE LEARNING UNTUK KLASIFIKASI

Logistic Regression


Support Vector Machine

CART

Naïve Bayes Classifier

KNN

Dan lain-lai




Concept and Definition of Logistic Regression



Konsep Regresi Regresi

- **Regresi Logistik** digunakan untuk membuat model prediksi dengan variabel dependen yang berskala dikotomi.
- Skala dikotomi yang dimaksud adalah skala data nominal dengan dua kategori, misalnya: **"Ya dan Tidak"**, **"Baik dan Buruk"** atau **"Tinggi dan Rendah"**.



Ilustrasi Penggunaan Regresi Logistik

Sebuah bank ingin melakukan prediksi apakah nasabahnya memiliki kemampuan membayar kredit atau tidak.

Peneliti melakukan identifikasi faktor apa saja yang dapat mempengaruhi kemampuan nasabah dalam membayar kredit, dan beberapa faktor yang diidentifikasi adalah:

- Penghasilan
- Riwayat kredit
- Resiko kesehatan nasabah
- Inklusi keuangan

Dependen (Y)	Kemampuan membayar nasabah (Yes/No), Yes = 1 dan No = 0
Independen (X)	• Penghasilan • Riwayat kredit • Resiko kesehatan • Inklusi keuangan



Tujuan Regresi Logistik

Menghitung peluang, persamaan yang diperoleh dari proses regresi logistik dapat digunakan untuk menghitung peluang responden di luar responden yang termasuk dalam penelitian.

Contoh yang dapat dipahami adalah proses pengajuan kredit. Pihak bank biasanya melakukan evaluasi kelayakan seseorang layak atau tidak untuk menerima kredit pinjaman dari bank. Beberapa pertanyaan diberikan kepada pihak bank terhadap calon penerima kredit seputar karakteristik variabel calon penerima modal tersebut, dan variabel-variabel tersebut merupakan variabel independen yang akan diinput oleh petugas bank ke dalam model.

Dari beberapa variabel yang dipertanyakan itulah, petugas bank dapat menentukan peluang calon penerima kredit tersebut untuk bisa mengembalikan pinjaman atau tidak dengan nilai antara 0–1.



Tujuan Regresi Logistik

Regresi Logistik ini sering digunakan untuk **melihat perbedaan karakteristik antara 2 kelompok/klasifikasi** dengan menghitung odds ratio masing-masing variabel independen, untuk rasio perbandingan antara dua kelompok terhadap variabel independen tersebut.

Misalnya terdapat dua kelompok petani, yaitu: petani anorganik dan petani organik.

Odds ratio dapat menggambarkan bahwa peluang petani mampu beralih dari anorganik ke organik adalah karena perbedaan harga produk hasil kedua proses tersebut.

Petani organik bersedia beralih dari anorganik ke organik meskipun produktivitas organik lebih kecil dibanding anorganik. Namun, perbedaan harga yang tinggi menjadikan petani organik memiliki pendapatan yang lebih tinggi dibandingkan petani anorganik.



Tujuan Regresi Logistik

Peneliti mampu **mengetahui faktor yang mempengaruhi mengapa terdapat perbedaan antara kedua kelompok** tersebut.

Misalnya contoh dua kelompok petani sebelumnya, organik dan anorganik, dan kita ingin mengetahui faktor apa yang paling mempengaruhi seseorang memutuskan sebagai petani organik atau anorganik. Diketahui bahwa harga merupakan faktor yang paling berpengaruh terhadap preferensi petani memilih pertanian organik. Jika ingin mengembangkan pertanian organik, pemerintah harus melakukan kebijakan yang tetap menstabilkan harga agar terus berada di atas harga produk anorganik, sehingga peminat petani organik akan semakin banyak dan bisa terus berkembang.



Checkpoint

Perhatikan metode-metode berikut:

Logistic Regression

Support Vector Machine

CART

RFM

Naïve Bayes Classifier

KNN

K-means

Mana yang dapat digunakan untuk melakukan klasifikasi?



Evaluation Metrics

Saat melakukan evaluasi model dengan pemilihan metrics, pastikan bahwa Anda mengetahui konteks dan tujuan Anda.



Confusion Matrix

Digunakan untuk binary classification.

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN



Accuracy

Digunakan untuk binary classification.

$$Accuracy = \frac{TP+TN}{TP+FP+TN+FN}$$

Accuracy didapat dari semua prediksi yang benar dibagi dengan total keseluruhan hasil prediksi.

TP	FP
FN	TN



Recall

$$Recall = \frac{TP}{TP+FN}$$

Recall digunakan untuk menilai berapa banyak prediksi positif yang benar di antara keseluruhan positive class.

TP	FP



Precision

$$Precision = \frac{TP}{TP+FP}$$

Precision digunakan untuk mengetahui banyaknya nilai yang benar di antara semua yang diprediksi positif.

TP	FP
FN	TN



F-Score/F-Measure

$$F - measure = \frac{2 * Recall * Precision}{Recall + Precision}$$

F-score / F-measure digunakan ketika sulit untuk membandingkan 2 model yang memiliki precision rendah dan recall yang tinggi ataupun sebaliknya.

