

K-Means Clustering

Muhammad Saipul Rohman, S.SI, M.Kom




Outline

- Concept and Definition of Clustering
- Step by step K-Means Clustering
- Hands On Logistic K-Means Clustering using Python



Concept and Definition of Clustering





Clustering


Clustering merupakan teknik pengelompokan berdasarkan kesamaan karakteristik data

Konsep algoritma dari clustering adalah membagi populasi ke dalam grup yang berbeda, sehingga setiap titik data serupa dengan titik data dalam grup yang sama dan tidak serupa dengan poin data di grup lain.

Menetapkan sub-kelompok berdasarkan kesamaan dan ketidaksamaan.



Ilustrasi Penggunaan Clustering




K-Means Clustering

K-means clustering adalah algoritma iteratif yang memartisi sekelompok data ke dalam beberapa sub kelompok berdasarkan nilai rata-rata terdekat.

Ilustrasinya, bahwa jika diberi sekelompok objek, k-means mempartisi kelompok itu menjadi beberapa sub-kelompok. Sub-kelompok dibentuk berdasarkan kemiripan dan jarak setiap titik data dalam sub-kelompok tersebut dengan rata-rata centroidnya.

Tujuan dari k-means clustering adalah untuk meminimalkan jarak *Euclidean* yang dimiliki setiap titik dari pusat cluster. Ini dikenal sebagai varian intra-cluster.





*biru adalah rata-rata dalam setiap sub-group.



Ilustrasi Proses K-Means Clustering




Hasil bangkitan data terlihat ada 4 kelompok yang terpisah.



Setiap kelompok akan memiliki centroid masing-masing.



Proses Algoritma K-Means



Centroid akan berpindah mengikuti kumpulan data baru dalam satu kelompok tersebut.



Step by step K-Means



Memilih Indikator

Memilih indikator yang akan digunakan dalam clustering

Tujuan bisnis yang akan dilakukan pada sebuah penelitian adalah bagaimana melakukan pengelompokan nilai gizi balita dengan metode k-means.

Penelitian dibuat menggunakan data primer, dengan respondennya adalah balita-balita di bawah usia 36 bulan yang ada di data POSYANDU.

Balita ke-	Tinggi Badan (TB)	Berat Badan (BB)
Balita 1	65	5,8
Balita 2	65	7,2
Balita 3	60	5
Balita 4	60	8
Balita 5	52	5,8
Balita 6	51	5

Indikator yang digunakan untuk melakukan pengelompokan status gizi balita berjumlah 2, yaitu **tinggi badan balita (TB)** dan **berat badan balita (BB)**.



Menentukan Nilai K (Jumlah Kelompok)

Menentukan nilai k (jumlah kelompok) yang akan dibentuk dalam proses k-means dapat dilakukan dengan tiga cara:


- Peneliti dapat menentukan nilai sendiri.
- Jika peneliti belum ada jumlah kelompok yang akan dibentuk, dapat menggunakan metode **elbow**.
- Selain metode **elbow**, metode **silhouette score** juga dapat digunakan untuk menentukan nilai k optimum.



Metode Elbow

Metode Elbow merupakan suatu metode yang digunakan untuk menghasilkan informasi dalam menentukan jumlah cluster terbaik, dengan cara melihat persentase hasil perbandingan antara jumlah cluster yang akan membentuk siku pada suatu titik.

Pada grafik di samping, ditentukan jumlah kelompok ada pada titik siku-siku, yaitu 4 kelompok.



Gambar 1. Jumlah cluster optimal



Clustering Performance Evaluation Metrics

Silhouette Coefficient

Dalam menentukan banyak cluster (k) yang optimal, selain menggunakan metode elbow, metode lain yang dapat digunakan adalah memakai silhouette analysis. Metode ini digunakan untuk menentukan derajat pemisah antar cluster. Interval dari koefisien ini berada dalam range $[-1, 1]$ dengan ketentuan sebagai berikut:

0 : Jarak cluster terlalu dekat dengan tetangga

1 : Optimal cluster

-1 : Cluster tidak sesuai



K-Means

Hal yang harus diperhatikan saat menggunakan K-means

1. Hasil optimal secara keseluruhan mungkin tidak tercapai
2. Jumlah cluster harus dipilih terlebih dahulu
3. K-means terbatas pada batas cluster linier
4. K-means bisa lambat untuk sejumlah besar sampel



Clustering

Aplikasi Clustering dalam Skenario Dunia Nyata

1. Segmentasi pelanggan
2. Pengelompokan Dokumen
3. Segmentasi Gambar
4. Mesin Rekomendasi

